SQL databases and R

i Use the conflicted package (http://conflicted.r-lib.org/) to force all conflicts to become

The portal_mammals database

Connecting to databases

```
library(dplyr)
library(dbplyr)
```

```
Attaching package: 'dbplyr'
The following objects are masked from 'package:dplyr':
    ident, sql
mammals <- DBI::dbConnect(RSQLite::SQLite(), "data_raw/portal_mammals.sqlite")</pre>
## A closer look at how connected mammals database looks like
src_dbi(mammals)
src: sqlite 3.46.0 [/Users/namigabbasov/Desktop/R-Data-Carpentry/data_raw/portal_mammals.sq
tbls: plots, species, surveys
#three tables: plots, species, surveys
## Querying the database with the SQL syntax
tbl(mammals, sql("SELECT year, species_id, plot_id FROM surveys"))
# Source:
            SQL [?? x 3]
# Database: sqlite 3.46.0 [/Users/namigabbasov/Desktop/R-Data-Carpentry/data_raw/portal_mamm.
    year species_id plot_id
   <int> <chr>
                      <int>
 1 1977 NL
                          2
 2 1977 NL
                          3
 3 1977 DM
                          2
 4 1977 DM
                          7
 5 1977 DM
                          3
 6 1977 PF
                          1
 7 1977 PE
                          2
 8 1977 DM
                          1
 9 1977 DM
                          1
10 1977 PF
                          6
# i more rows
## Querying the database with the dplyr syntax
surveys <- tbl(mammals, "surveys")</pre>
surveys %>%
   select(year, species_id, plot_id)
```

Source: SQL [?? x 3]

Database: sqlite 3.46.0 [/Users/namigabbasov/Desktop/R-Data-Carpentry/data_raw/portal_mammayear species_id plot_id

look first ten observations
head(surveys, n = 10)

Source: SQL [10 x 9]

Database: sqlite 3.46.0 [/Users/namigabbasov/Desktop/R-Data-Carpentry/data_raw/portal_mammarecord id month day year plot id species id sex hindfoot length weight

	100014_14	monon	aay	your	Proo_ra	ppoored_ra	0021	minarooo_rengen	WOTE110
	<int></int>	<int></int>	<int></int>	<int></int>	<int></int>	<chr></chr>	<chr></chr>	<int></int>	<int></int>
1	1	7	16	1977	2	NL	M	32	NA
2	2	7	16	1977	3	NL	M	33	NA
3	3	7	16	1977	2	DM	F	37	NA
4	4	7	16	1977	7	DM	M	36	NA
5	5	7	16	1977	3	DM	M	35	NA
6	6	7	16	1977	1	PF	M	14	NA
7	7	7	16	1977	2	PE	F	NA	NA
8	8	7	16	1977	1	DM	M	37	NA
9	9	7	16	1977	1	DM	F	34	NA
10	10	7	16	1977	6	PF	F	20	NA

difference between read_csv and database
nrow(surveys)

[1] NA

```
#SQL translation
show_query(head(surveys, n = 10))

<SQL>
SELECT `surveys`.*
FROM `surveys`
LIMIT 10
```

Simple database queries

```
surveys %>%
 filter(weight < 5) %>%
 select(species_id, sex, weight)
# Source:
           SQL [?? x 3]
# Database: sqlite 3.46.0 [/Users/namigabbasov/Desktop/R-Data-Carpentry/data_raw/portal_mamm
  species_id sex
                   weight
  <chr>
             <chr> <int>
1 PF
             Μ
2 PF
             F
                        4
3 PF
            <NA>
4 PF
             F
                        4
5 PF
            F
                        4
6 RM
            M
                        4
7 RM
            F
                        4
```

i more rows

Μ

Μ

М

Laziness

8 RM

9 RM

10 RM

```
## dplyr never pulls data into R unless you explicitly ask for it
data_subset <- surveys %>%
  filter(weight < 5) %>%
  select(species_id, sex, weight)
```

4

4

```
data_subset %>%
         select(-sex)
                                                         SQL [?? x 2]
 # Source:
 # Database: sqlite 3.46.0 [/Users/namigabbasov/Desktop/R-Data-Carpentry/data_raw/portal_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_ma
               species_id weight
                                                                        <int>
               <chr>>
     1 PF
                                                                                           4
     2 PF
                                                                                           4
     3 PF
                                                                                           4
     4 PF
                                                                                           4
                                                                                           4
     5 PF
                                                                                           4
     6 RM
     7 RM
                                                                                           4
                                                                                           4
    8 RM
    9 RM
                                                                                           4
 10 RM
                                                                                           4
 # i more rows
# To retrieve all of the query results from the database, we add the collect() command to our
data_subset <- surveys %>%
         filter(weight < 5) %>%
         select(species_id, sex, weight) %>%
          collect()
 data_subset
 # A tibble: 17 x 3
              species\_id sex
                                                                                               weight
               <chr>
                                                                   <chr> <int>
     1 PF
                                                                  Μ
     2 PF
                                                                   F
                                                                                                                        4
```

3 PF

4 PF

5 PF

6 RM

7 RM

8 RM

9 RM

10 RM

11 RM

12 RM

<NA>

F

F

Μ

F

Μ

Μ

Μ

Μ

F

4

4

4 4

4

4

4

4 4

4

```
13 RM M 4
14 RM M 4
15 RM M 4
16 PF M 4
17 PP M 4
```

Complex database queries

```
plots <- tbl(mammals, "plots")</pre>
plots
 # Source:
                                                              table<`plots`> [?? x 2]
 # Database: sqlite 3.46.0 [/Users/namigabbasov/Desktop/R-Data-Carpentry/data_raw/portal_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_mammaterial_ma
               plot_id plot_type
                          <int> <chr>
                                                1 Spectab exclosure
      1
      2
                                                2 Control
      3
                                                3 Long-term Krat Exclosure
      4
                                               4 Control
      5
                                               5 Rodent Exclosure
     6
                                               6 Short-term Krat Exclosure
     7
                                              7 Rodent Exclosure
     8
                                              8 Control
     9
                                                9 Spectab exclosure
 10
                                          10 Rodent Exclosure
 # i more rows
 ## The plot_id column also features in the surveys table
 surveys
```

Source: table<`surveys`> [?? x 9]

									
1	1	7	16	1977	2	NL	M	32	NA
2	2	7	16	1977	3	NL	M	33	NA
3	3	7	16	1977	2	DM	F	37	NA
4	4	7	16	1977	7	DM	M	36	NA
5	5	7	16	1977	3	DM	M	35	NA
6	6	7	16	1977	1	PF	M	14	NA

```
7
           7
                 7
                      16 1977
                                      2 PE
                                                   F
                                                                       NA
                                                                              NA
 8
                      16 1977
                                      1 DM
                                                                       37
           8
                                                   Μ
                                                                              NA
 9
           9
                 7
                      16 1977
                                      1 DM
                                                   F
                                                                       34
                                                                              NA
10
          10
                 7
                      16 1977
                                      6 PF
                                                   F
                                                                       20
                                                                              NA
# i more rows
## Inner join
plots %>%
  filter(plot_id == 1) %>%
  inner_join(surveys) %>%
  collect()
Joining with `by = join_by(plot_id)`
```

```
# A tibble: 1,995 x 10
  plot_id plot_type
                                               day year species_id sex
                             record_id month
    <int> <chr>
                                 <int> <int> <int> <int> <chr>
                                                                    <chr>>
 1
         1 Spectab exclosure
                                     6
                                           7
                                                16 1977 PF
                                                                    М
2
                                     8
                                           7
                                                16 1977 DM
         1 Spectab exclosure
                                                                    Μ
3
         1 Spectab exclosure
                                   9
                                           7
                                                16 1977 DM
                                                                    F
4
                                    78
         1 Spectab exclosure
                                           8
                                                19 1977 PF
                                                                    Μ
5
         1 Spectab exclosure
                                    80
                                           8
                                                19 1977 DS
                                                                    Μ
6
         1 Spectab exclosure
                                   218
                                           9
                                                13 1977 PF
                                                                    М
7
         1 Spectab exclosure
                                   222
                                           9
                                                13 1977 DS
                                                                    М
8
         1 Spectab exclosure
                                   239
                                           9
                                                13 1977 DS
                                                                    Μ
9
                                                16 1977 DM
         1 Spectab exclosure
                                   263
                                          10
                                                                    Μ
                                                                    F
10
         1 Spectab exclosure
                                   270
                                          10
                                                16 1977 DM
# i 1,985 more rows
```

i 2 more variables: hindfoot_length <int>, weight <int>

```
## Left Join
species <- tbl(mammals, "species")</pre>
unique_genera <- left_join(surveys, plots) %>%
    left_join(species) %>%
    group_by(plot_type) %>%
    summarize(
        n_genera = n_distinct(genus)
    ) %>%
    collect()
```

```
Joining with `by = join_by(plot_id)`
Joining with `by = join_by(species_id)`
```

Creating a new SQLite database

```
## download files
download.file("https://ndownloader.figshare.com/files/3299483",
             "data_raw/species.csv")
download.file("https://ndownloader.figshare.com/files/10717177",
             "data raw/surveys.csv")
download.file("https://ndownloader.figshare.com/files/3299474",
             "data_raw/plots.csv")
## import files
species <- read_csv("data_raw/species.csv")</pre>
Rows: 54 Columns: 4
-- Column specification ------
Delimiter: ","
chr (4): species_id, genus, species, taxa
i Use `spec()` to retrieve the full column specification for this data.
i Specify the column types or set `show_col_types = FALSE` to quiet this message.
surveys <- read_csv("data_raw/surveys.csv")</pre>
Rows: 35549 Columns: 9
-- Column specification -----
Delimiter: ","
chr (2): species_id, sex
dbl (7): record_id, month, day, year, plot_id, hindfoot_length, weight
i Use `spec()` to retrieve the full column specification for this data.
i Specify the column types or set `show_col_types = FALSE` to quiet this message.
plots <- read_csv("data_raw/plots.csv")</pre>
Rows: 24 Columns: 2
-- Column specification ------
Delimiter: ","
chr (1): plot_type
dbl (1): plot_id
```

- i Use `spec()` to retrieve the full column specification for this data.
- i Specify the column types or set `show_col_types = FALSE` to quiet this message.